Executive Summary

하나의 GPU에서 두 AI 서비스의 간섭을 줄이는 운영 정책

CJ 4DPLEX AI Platform 개발 사전과제 | 안하민 | 2026-11-12

문제와 목표

한 대의 DGX Spark에서 문장을 생성하는 Qwen3.5-9B와 이미지를 검출하는 YOLO26l을 함께 운영했다. 모델 정확도 향상이 아니라, 서로 다른 AI 작업이 같은 GPU를 쓸 때 생기는 지연을 측정하고 안정적으로 요청을 처리하는 것이 목표다.

주요 시나리오는 **Qwen10건·YOLO300건이 한꺼번에 제출되는 제작 작업 묶음**이다. 실제 회사 트래픽을 수집한 것은 아니다. Qwen 전체 응답시간을 악화시키지 않으면서 YOLO의 늦은 응답(p95)을20% 이상 줄이는 상대 목표를 합의했다. Burst 결과를 탐색한 뒤 목표를 정했다는 점을 밝히며 사전등록된 독립 검증처럼 설명하지 않는다.

접근 방법

- 두 모델을 별도 컨테이너·Kubernetes Pod로 배포하고, 모델별 독립 대기열과 Worker를 사용했다.
- 요청별 전체 지연, 대기시간, 모델 호출, GPU forward 구간과 자원·로그를 수집했다.
- 최적화 없음·일반 MPS·고정 SM 분할5개 조합을 같은 환경에서 각각5회 비교했다.
- 생성의 Prefill은 많은 SM에서 빨라졌지만 반복 Decode는 SM 수에 비례해 빨라지지 않았다. 이를 근거로 **Qwen8 / YOLO40 SM** 분배를 검증했다. 단순히 GPU 공유 기능을 켠 것만으로 개선됐다고 주장하지 않는다.

주요 결과 — 최적화 없음 대비

Burst 지표	최적화 없음	고정8/40	변화
YOLO300건 전체 완료 평균	16.322초	11.592초	**28.98% 단축**
YOLO 요청 E2E p95	14.963초	10.674초	**28.66% 감소**
Qwen 요청 E2E p95	113.299초	111.876초	약1.26% 감소

p95는 요청95%가 해당 시간 이내에 완료됐음을 나타내는 기술통계다. Burst p95는 조건별 요청을 합친 분포이며 실행 반복 단위는5회다. 전체 요청묶음 완료시간은 약1.30%만 줄었으므로 대폭적인 전체 처리량 개선으로 과장하지 않는다.

최적화의 적용 범위

최종 비교는 같은 입력·출력·Queue·Worker를 유지한 7조건 × 5회 Burst다. 본측정 10,850건과 워밍업 1,155건의 응답을 구분해 검증했다. 요청을 버리거나 모델 batch 크기를 늘려 작업량을 줄인 결과가 아니다.

• 측정한 분할 후보 중 8/40이 Qwen 전체 응답 유지와 YOLO 지연 개선에 유리했다. 모든 입력·업무·지표의 유일한 최적해라는 뜻은 아니다.

• YOLO가 먼저 끝나므로 전체 측정시간 내내 두 모델이 계속 경합한 것은 아니다. 다른 요청 도착 패턴·장기 운영으로 결과를 확대하지 않는다.

• SLO는 탐색 후 정한 상대 기준이며 관측 통과를 독립 검증된 운영 보장으로 설명하지 않는다.

비용과 운영 리스크

SM을 적게 받은 Qwen의 내부 첫 토큰 생성시간 평균은 **188→472ms**로 악화됐다. 최종 응답이 비슷하게 유지됐다는 사실이 첫 반응까지 유지됐다는 뜻은 아니다. 또한 단일 YOLO 모델 호출의 p95는 8/40보다 16/32가 낮았다. 최종 완료·첫 반응·개별 tail 중 무엇을 우선하는지에 따라 정책 선택이 달라진다.

GPU 공유는 메모리·대역폭·장애의 완전한 격리를 제공하지 않는다. UUID 응답 채널은 요청 혼선 방지이며 보안 인증이 아니다. 신뢰된 단일 호스트의 실험이며 외부 공개 서비스의 SLA나 장기 가용성을 보증하지 않는다.

장애 대응과 검증 범위

YOLO 자신의 CUDA 작업이 유휴이고 큐가 비었음을 확인한 뒤 Node를 강제 종료하고 **Kubernetes 기본 재시작**을 검증했다. 3회에서 종료 신호 직전부터 첫 정상 결과 수신까지 **4.163~4.504초**였다. 직접 만든 복구 최적화나 무중단 서비스 성과가 아니다. 진행 중 요청 보존, GPU 실행 중 장애, 반복 CrashLoop는 검증하지 않았다.

결론과 활용

하나의 GPU에서 모델별 자원 민감도를 측정하고 실행 정책을 바꾸면, 언어 모델의 전체 응답시간을 유지하면서 CV 대기와 완료시간을 줄일 수 있었다. 동시에 첫 토큰 비용과 고정 자원 배분·입력 범위의 한계를 공개해 정책의 적용 범위를 구분했다.

기존 운영 배포는 원래 설정으로 복구했다. 8/40은 검토 가능한 후보이며 사용자 승인 없이 상시 운영 설정을 바꾸지 않았다. 다음 단계는 실제 업무 입력과 우선순위에 맞춘 독립 검증, 필요한 health·요청 보존 수준 결정이다.

산출물: 소스·설정·재현 안내·구성도·기술 보고서·원시 결과 및 감사 기록. 모델/OSS/AI 보조 범위와 권리 미확정 사항은 별도 고지했다. 상세: 기술 보고서.